

SCHÖN, DASS IHR DA SEID

Willkommen!

Gleich geht’s los. Sucht euch einen Platz.

GARRELT

Hey Claude, mach die Trophäen auf meinem Profil richtig schön groß!



GARRELT

Ship it! 🚀

TEAM

Sieht super aus!



Code angeschaut? Nö.

Am nächsten Morgen …



Die Trophäen-Komponente steckt auch in der Freundesliste.

Home · Deine Freunde



GARRELT

Claude … was hast du gemacht?

CLAUDE

Die Trophäen größer. Überall. 😅




GARRELT
Und ich hab mir den Code nicht angeguckt.



Wer hat schon mal AI-Code geshippt, ohne ihn zu lesen?

DAS WARUM

Verification wird zum Engpass



Mehr Leute

Designer und PMs checken Code ein, mit AI



Mehr Code

Viel zu viel, um jede Zeile zu lesen



Unser Job

Guardrails bauen, statt allen Code zu lesen

GARRELT MOCK · LOTUM

Vertrauen ist gut, Screenshots sind besser

Wie wir Playwright als Guardrail für AI-Code einsetzen

ÜBER MICH

Garrelt Mock

Game Developer

Lotum · Mobile-Games mit Webtechnologien

programmier.bar · Co-Host im Podcast



KURZ ERKLÄRT

Was ist Playwright?

Für alle, die es noch nicht kennen

PLAYWRIGHT IN 30 SEKUNDEN

E2E-Testing-Tool für den Browser



Microsoft

Open Source, seit 2020, vom Puppeteer-Team



3 Engines

Chromium, Firefox, WebKit, eine API



Kein Nischentool

73 Mio. Downloads pro Woche

SO SIEHT EIN TEST AUS

Kein sleep, Playwright wartet selbst

```
test('Level startet', async ({ page }) => {
  await page.goto('/');
  await page.getByRole('button', { name: 'Spielen' }).click();
  await expect(page.getByText('Level 1')).toBeVisible();
  await expect(page).toHaveScreenshot('level-1.png');
});
```

WENN'S ROT WIRD

Der Test liefert den Beweis mit



Bild-Diff

Expected, Actual, Diff im HTML-Report



Video

Der ganze Lauf zum Nachschauen



Trace

Zeitreise: DOM, Netzwerk, Konsole

WAS ICH EUCH HEUTE ZEIGE

Drei Spiele, drei Setups



Word Blitz

Ein Screenshot pro Storybook-Story



Magic Museum

Ein Golden Path, vom ersten Start an



Word Puzzle Journey

Viele Journeys, Bilder im PR



Disclaimer



PROJEKT 1 VON 3

Word Blitz

Das **blitzschnelle Wortspiel** mit Duellen auf Zeit, in 16 Sprachen.

100+ Mio.
Spieler:innen weltweit

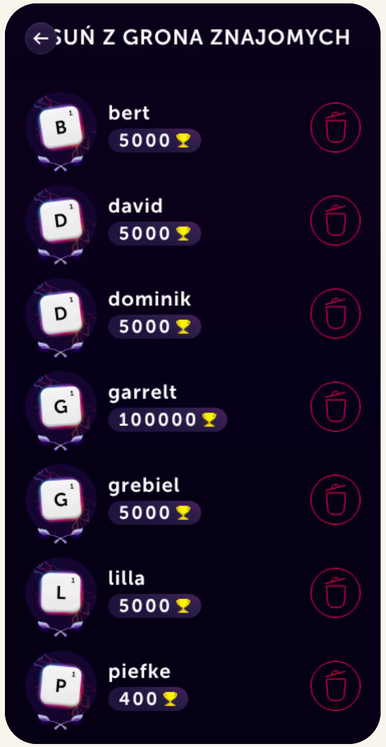
seit 2018
bei Lotum, erster Commit im Juli 2018

750
Vue-Komponenten im Client

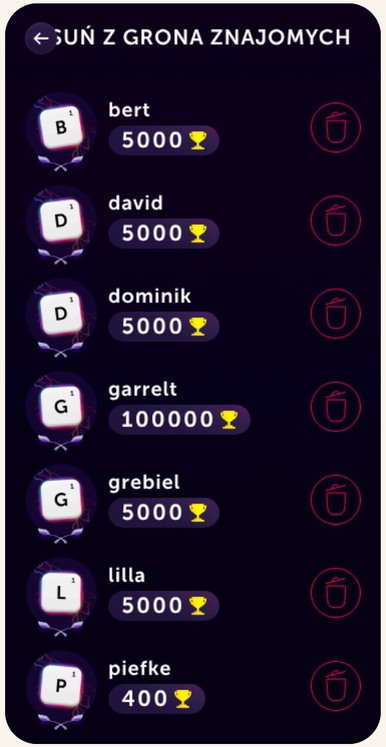
WORD BLITZ · VISUAL REGRESSION

Alter Screenshot gegen neuen

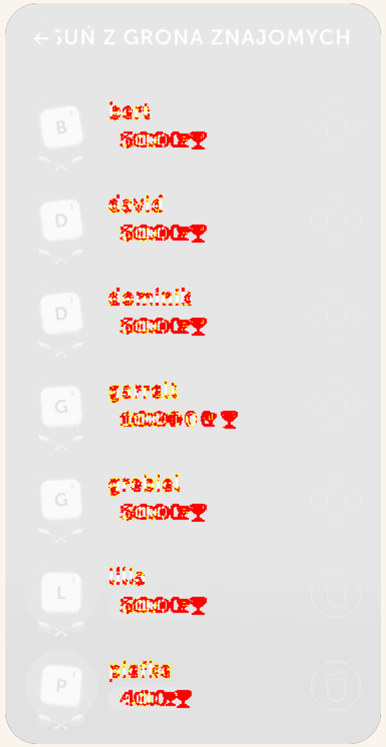
Expected · Baseline



Actual



Diff



Zwei Entscheidungen, die sich gelohnt haben



Nutzt, was schon da ist

Storybook oder Playground zeigen jeden Screen in jedem State. Daraus werden Screenshot-Tests, fast ohne Aufwand



Screenshots in Docker

Gleicher Browser, gleiches OS: keine Pixel-Unterschiede zwischen Mac, Linux und CI

WORD BLITZ · CODE

Neue Story = neuer Test, automatisch

```
for (const story of visualStories()) {   // Tag: visual
  test(story.name, async ({ page }) => {
    await stabilize(page)
    await page.goto(story.url)
    await waitForStoryFinished(page)
    await expect(page).toHaveScreenshot(`${story.name}.png`)
  })
}
```

WORD BLITZ · STABILISIERUNG

Zufall? Abgeschafft.

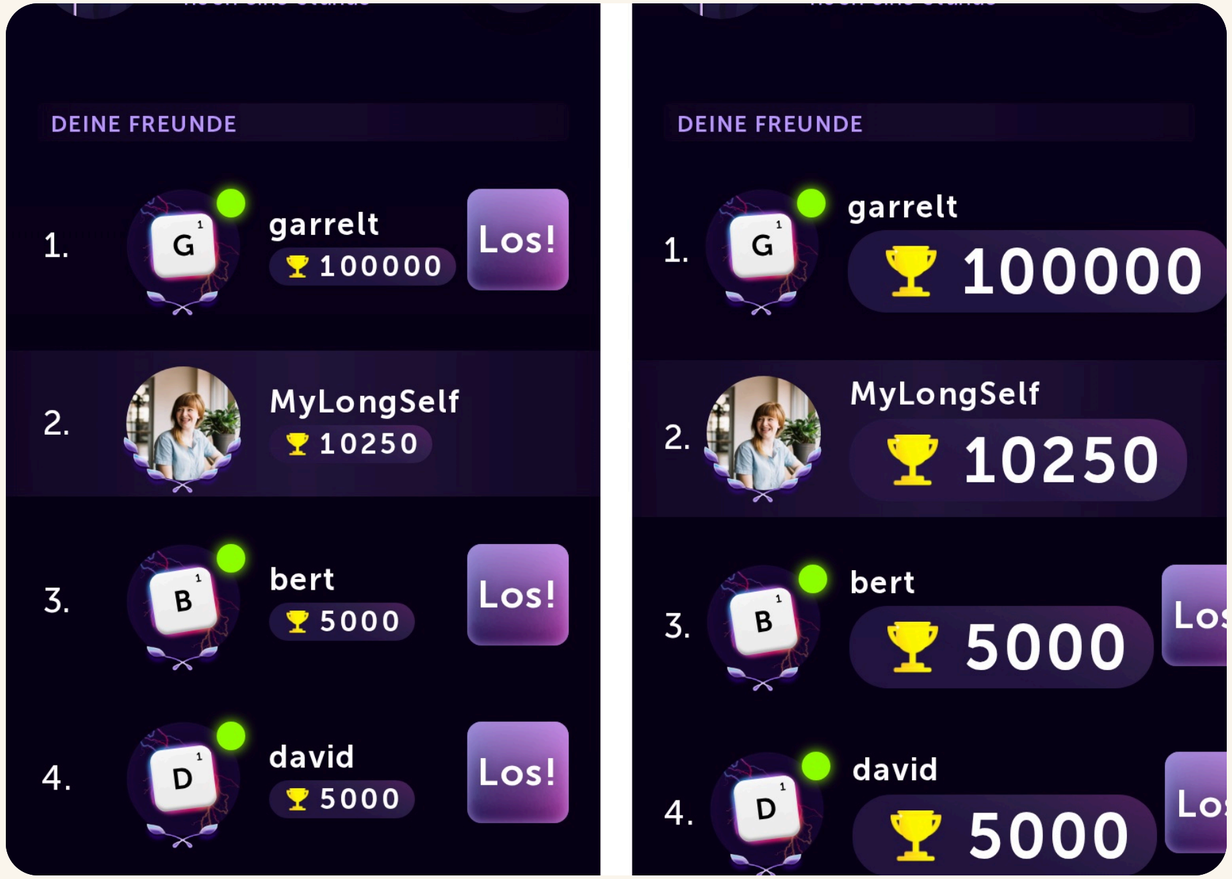
```
await page.clock.setFixedTime('2026-01-01T12:00Z')
await page.route(/* extern */, /* Fixture oder abort */)

Math.random = () => 0.5

await waitForStoryFinished(page)   // Animationen fertig
```

ZURÜCK ZUM COMIC

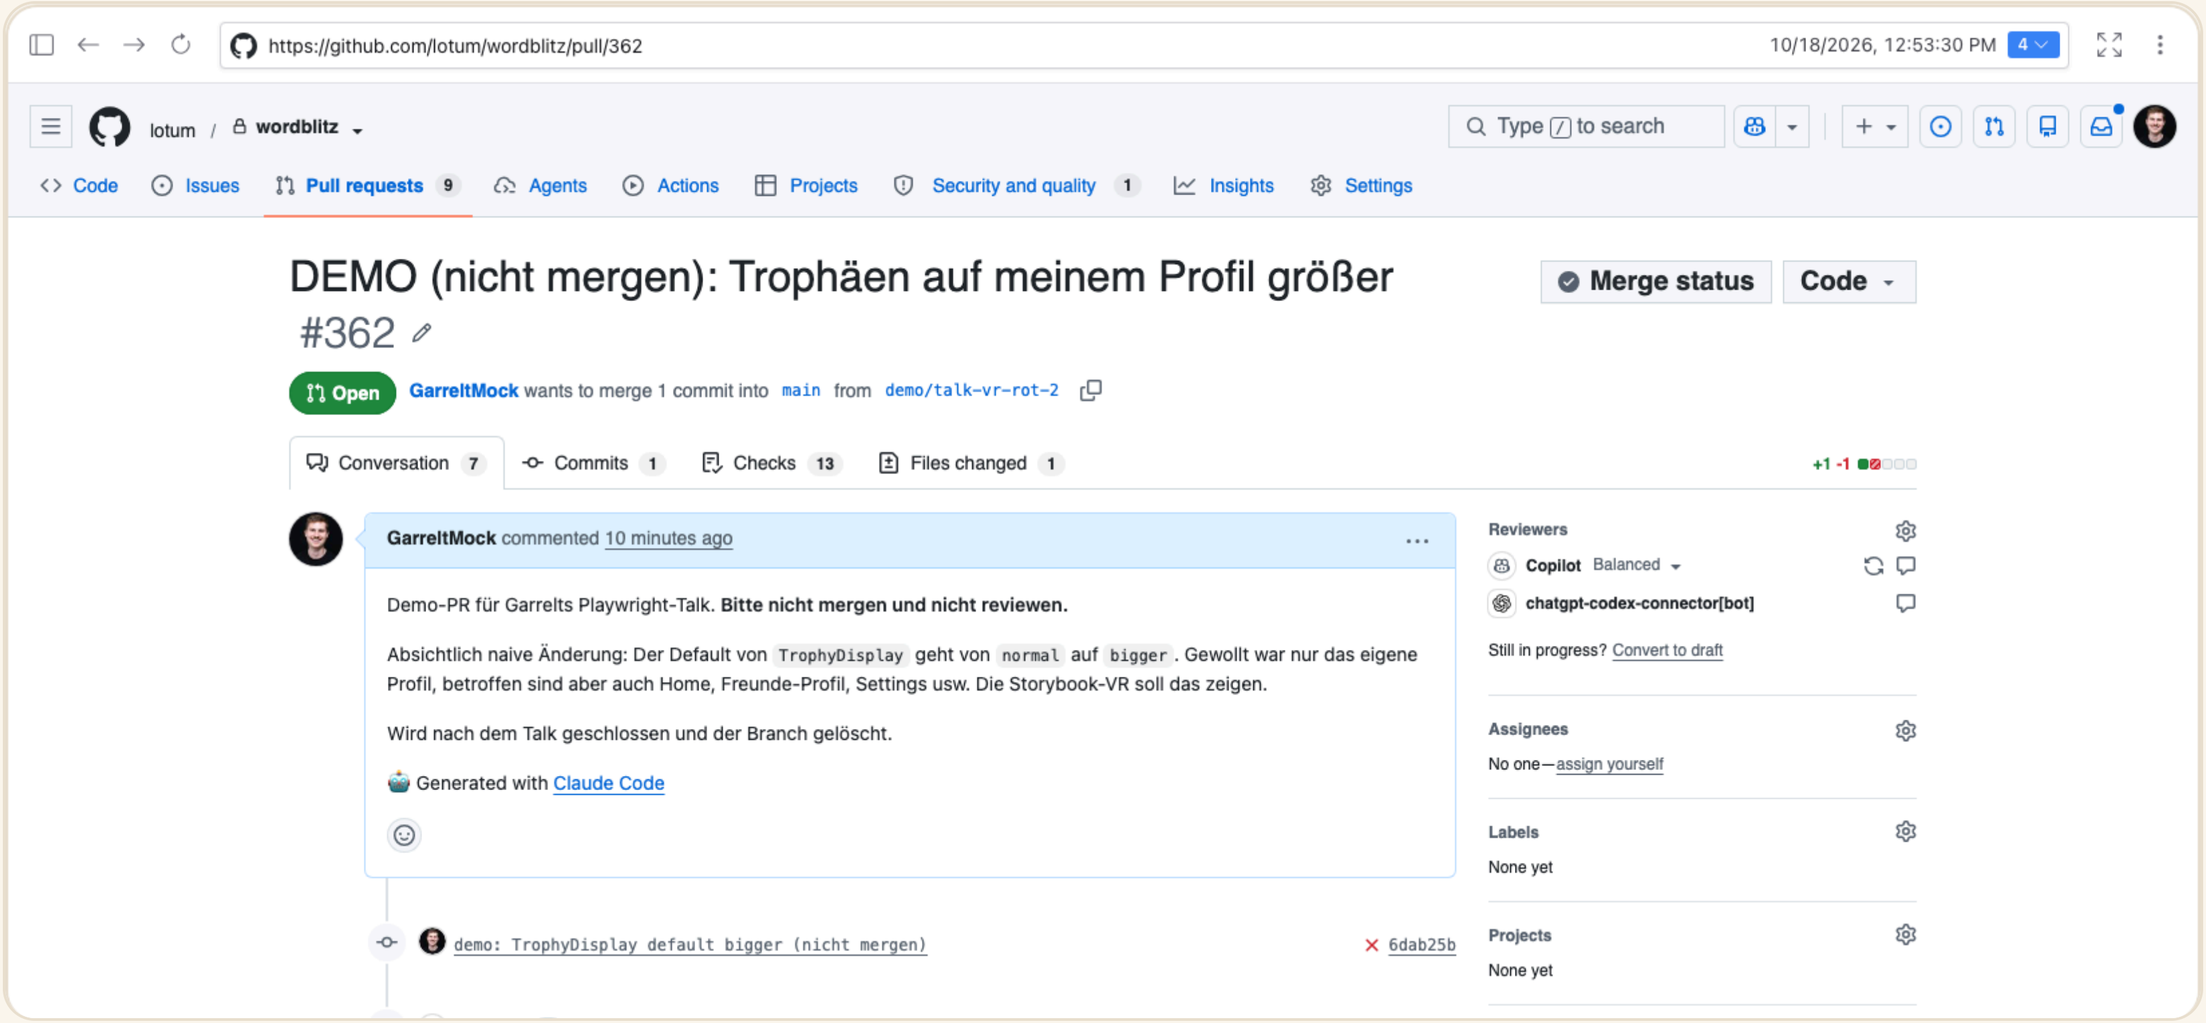
Das wäre rot geworden



PR #362: 32 rot, 427 grün

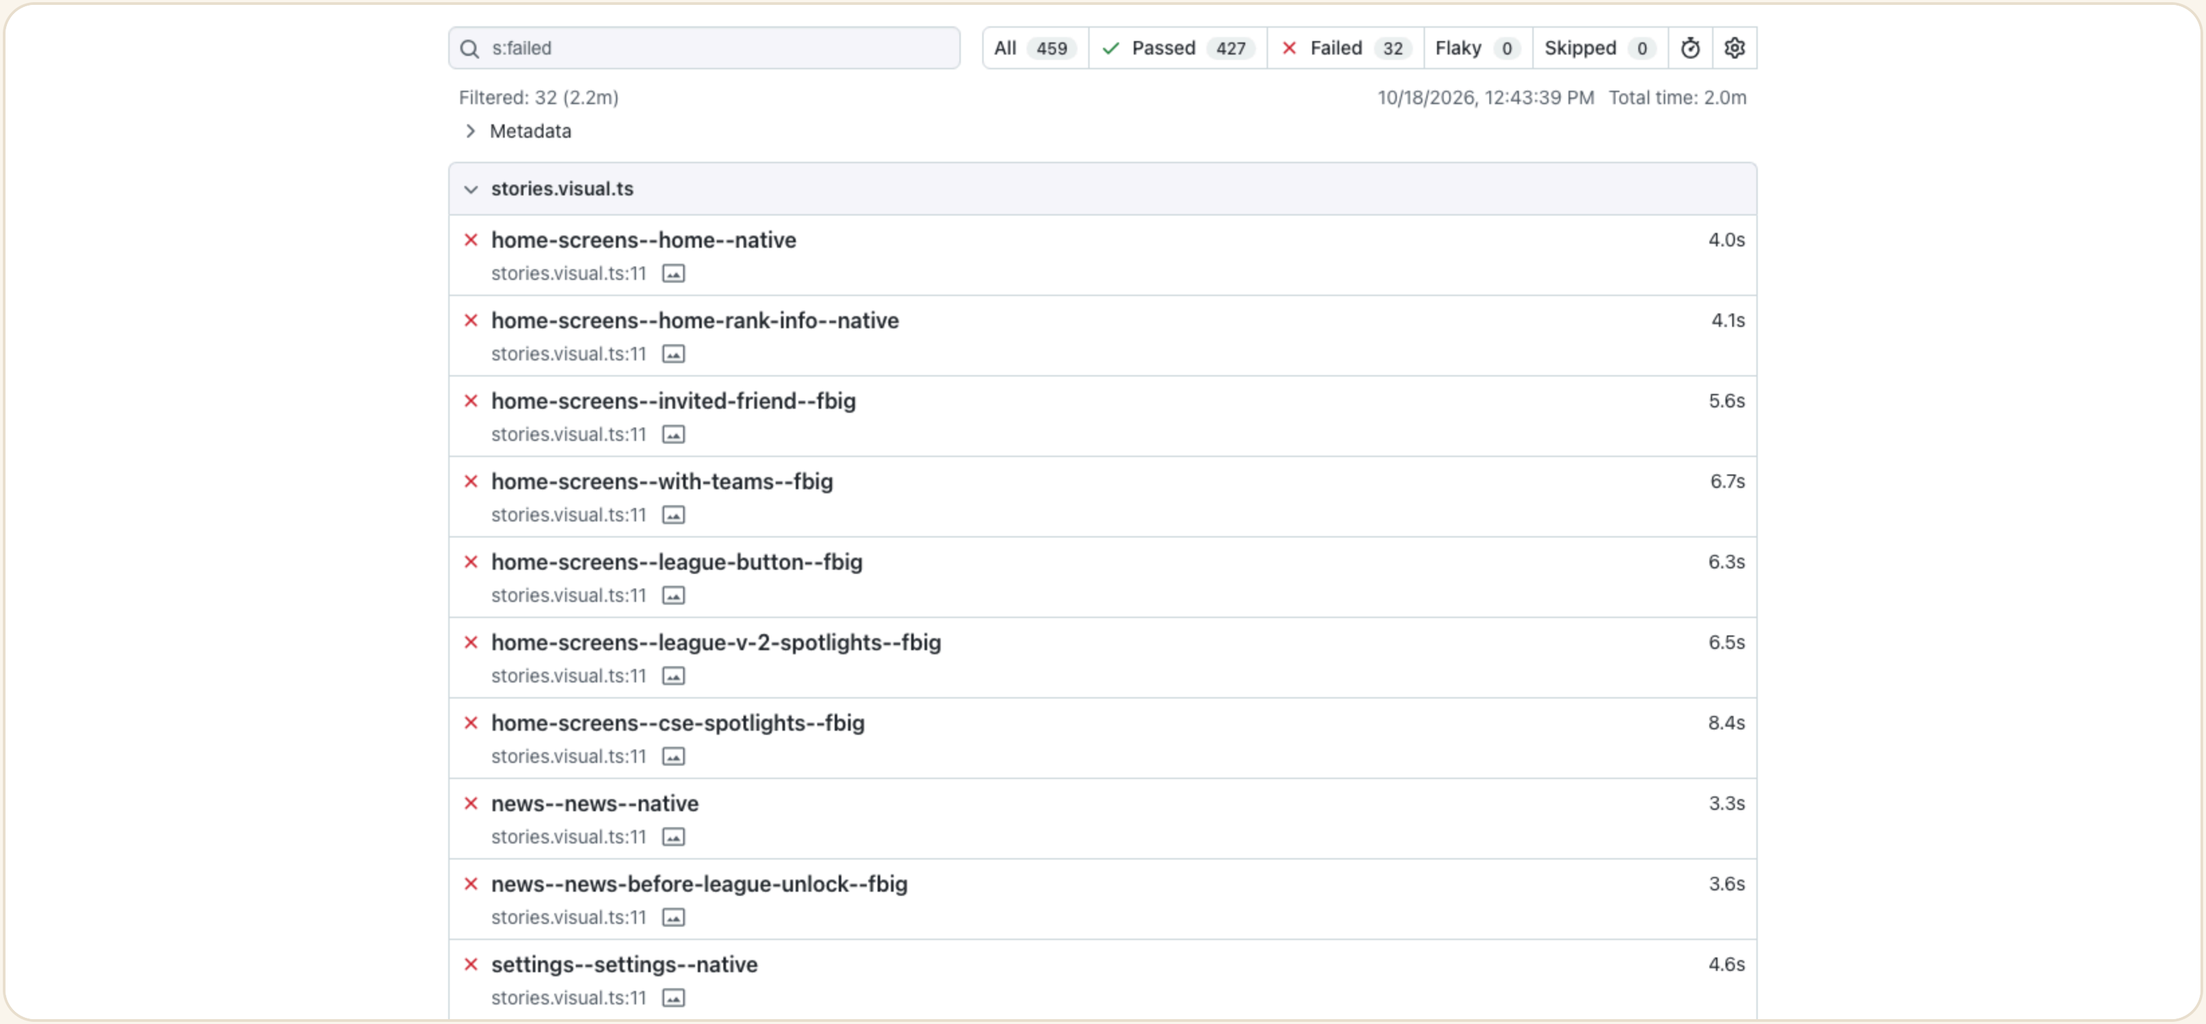
Home, Profil, Settings,
Freunde, News, Onboarding ...

So sieht das im PR aus



WORD BLITZ · PLAYWRIGHT-REPORT AUS DER CI

Expected, Actual, Diff



WORD BLITZ · WO DIE AI STOLPERT

Versteht die AI, was Rot bedeutet?

🤷‍♂️ **Diff gesehen, nicht verstanden:** „Ungewollte Diffs: keine“

♻️ **Baseline statt Fix:** alle Screenshots neu, ohne zu fragen

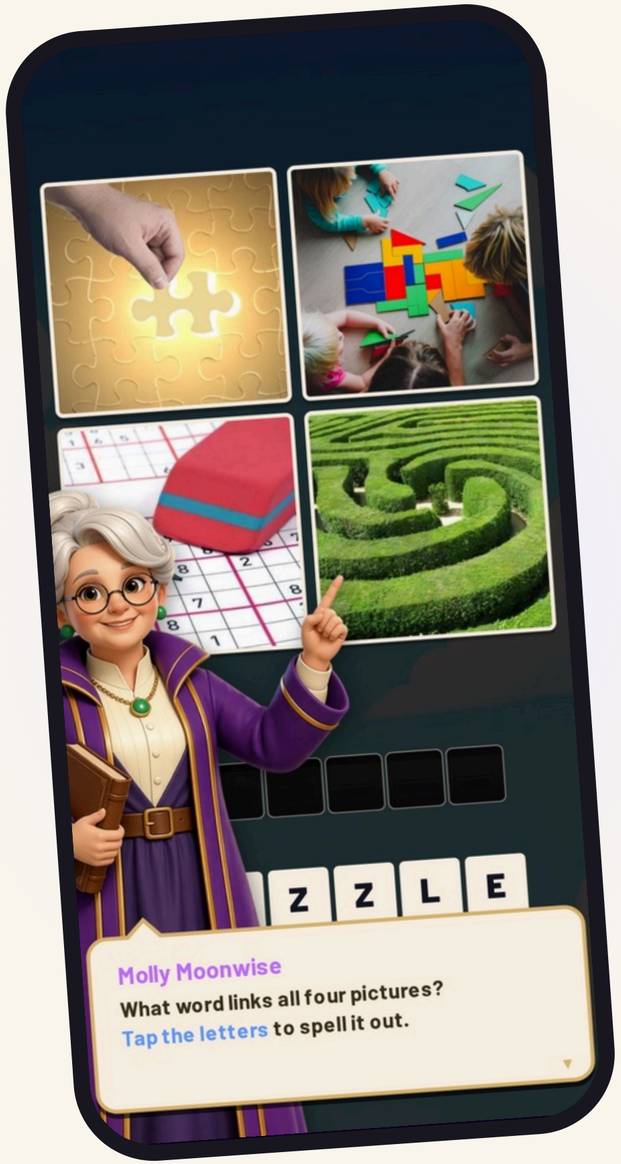
🙈 **Test abgeschaltet:** „Skip visual regression for new … entries“

📄 **Rule übergangen:** „Änderung abgeschlossen ✅“, ohne einen Diff anzuschauen

WORD BLITZ · SETUP-CHECK

Pixel-Vergleich: was klappt, was nicht

- ✅ Jede Story ist automatisch ein Test, **450+ Screens**
- ✅ Seiteneffekte auf **anderen Screens** fallen auf (PR #362: 32 rot)
- ⚠️ Rot ist **mehrdeutig**: Ob ein Diff gewollt ist, kann der Agent schlecht bewerten
- ⚠️ **Handarbeit:** Oft ist Rot gewollt. Ein Mensch prüft und erzeugt die Baselines neu
- ❌ **Nur Pixel:** keine States, keine Flows



PROJEKT 2 VON 3



Magic Museum

Der Nachfolger von **4 Bilder 1 Wort**: Welches Wort verbindet die vier Bilder? Mehrere Rätsel pro Level, gegen die Uhr.

Mai 2026
im Store, nach 3 Monaten Entwicklung

135
Svelte-Komponenten, SvelteKit + Capacitor

22
E2E-Tests

MAGIC MUSEUM · GOLDEN PATH

Anderer Fokus: Day-0-Experience

App-Start → Tutorial → Level 1–8 → Fail & Continue → Shop & Settings

Ein Test, 12 Schritte, 11 Screenshots, ein Video

MAGIC MUSEUM · WAS GEPRÜFT WIRD

Getestet wird, was fürs Business zählt



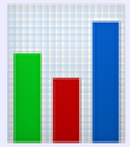
Flow

Der erste Start läuft flüssig



Münzen

Stand nach jedem Level



Tracking

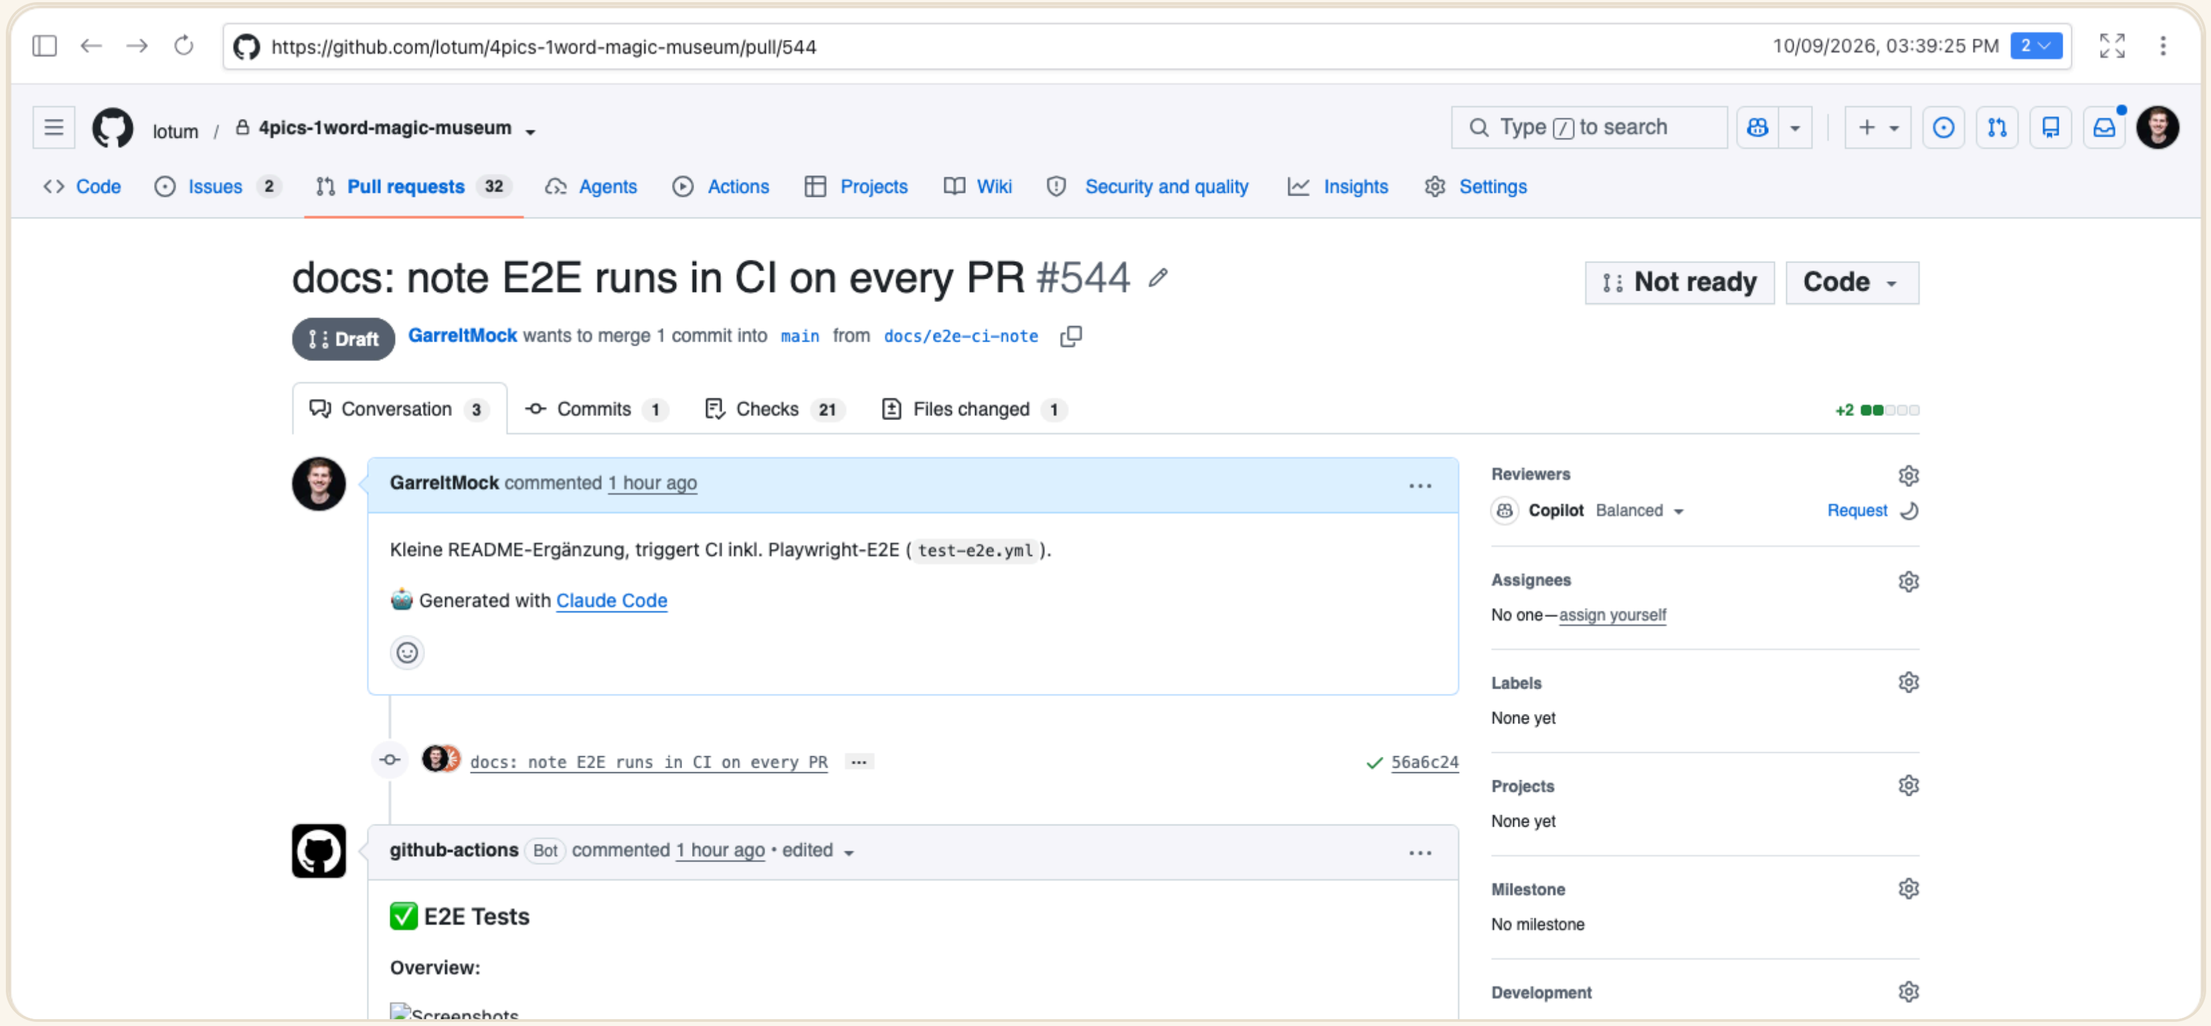
Sonst ist bezahlte UA blind



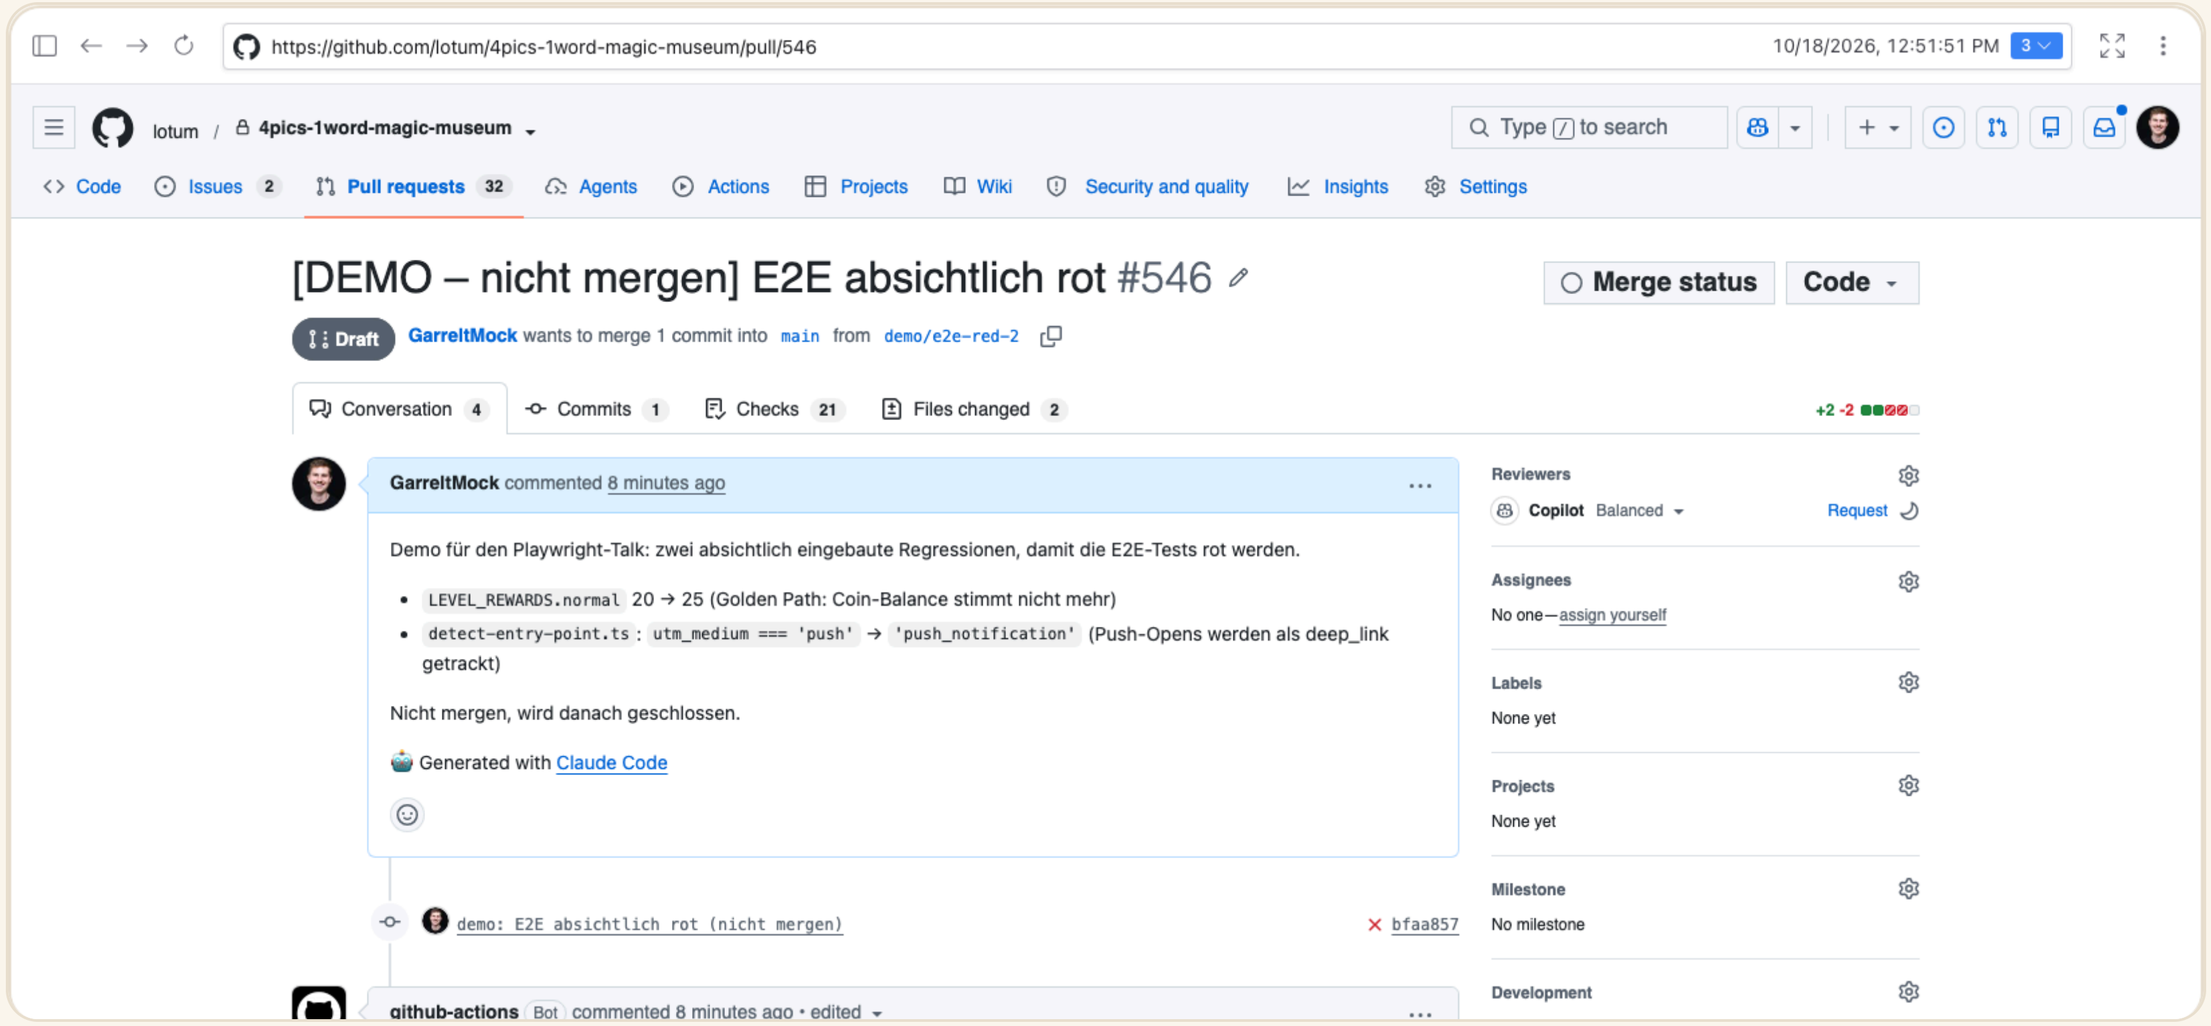
Upgrade

Alte Spielstände laufen weiter

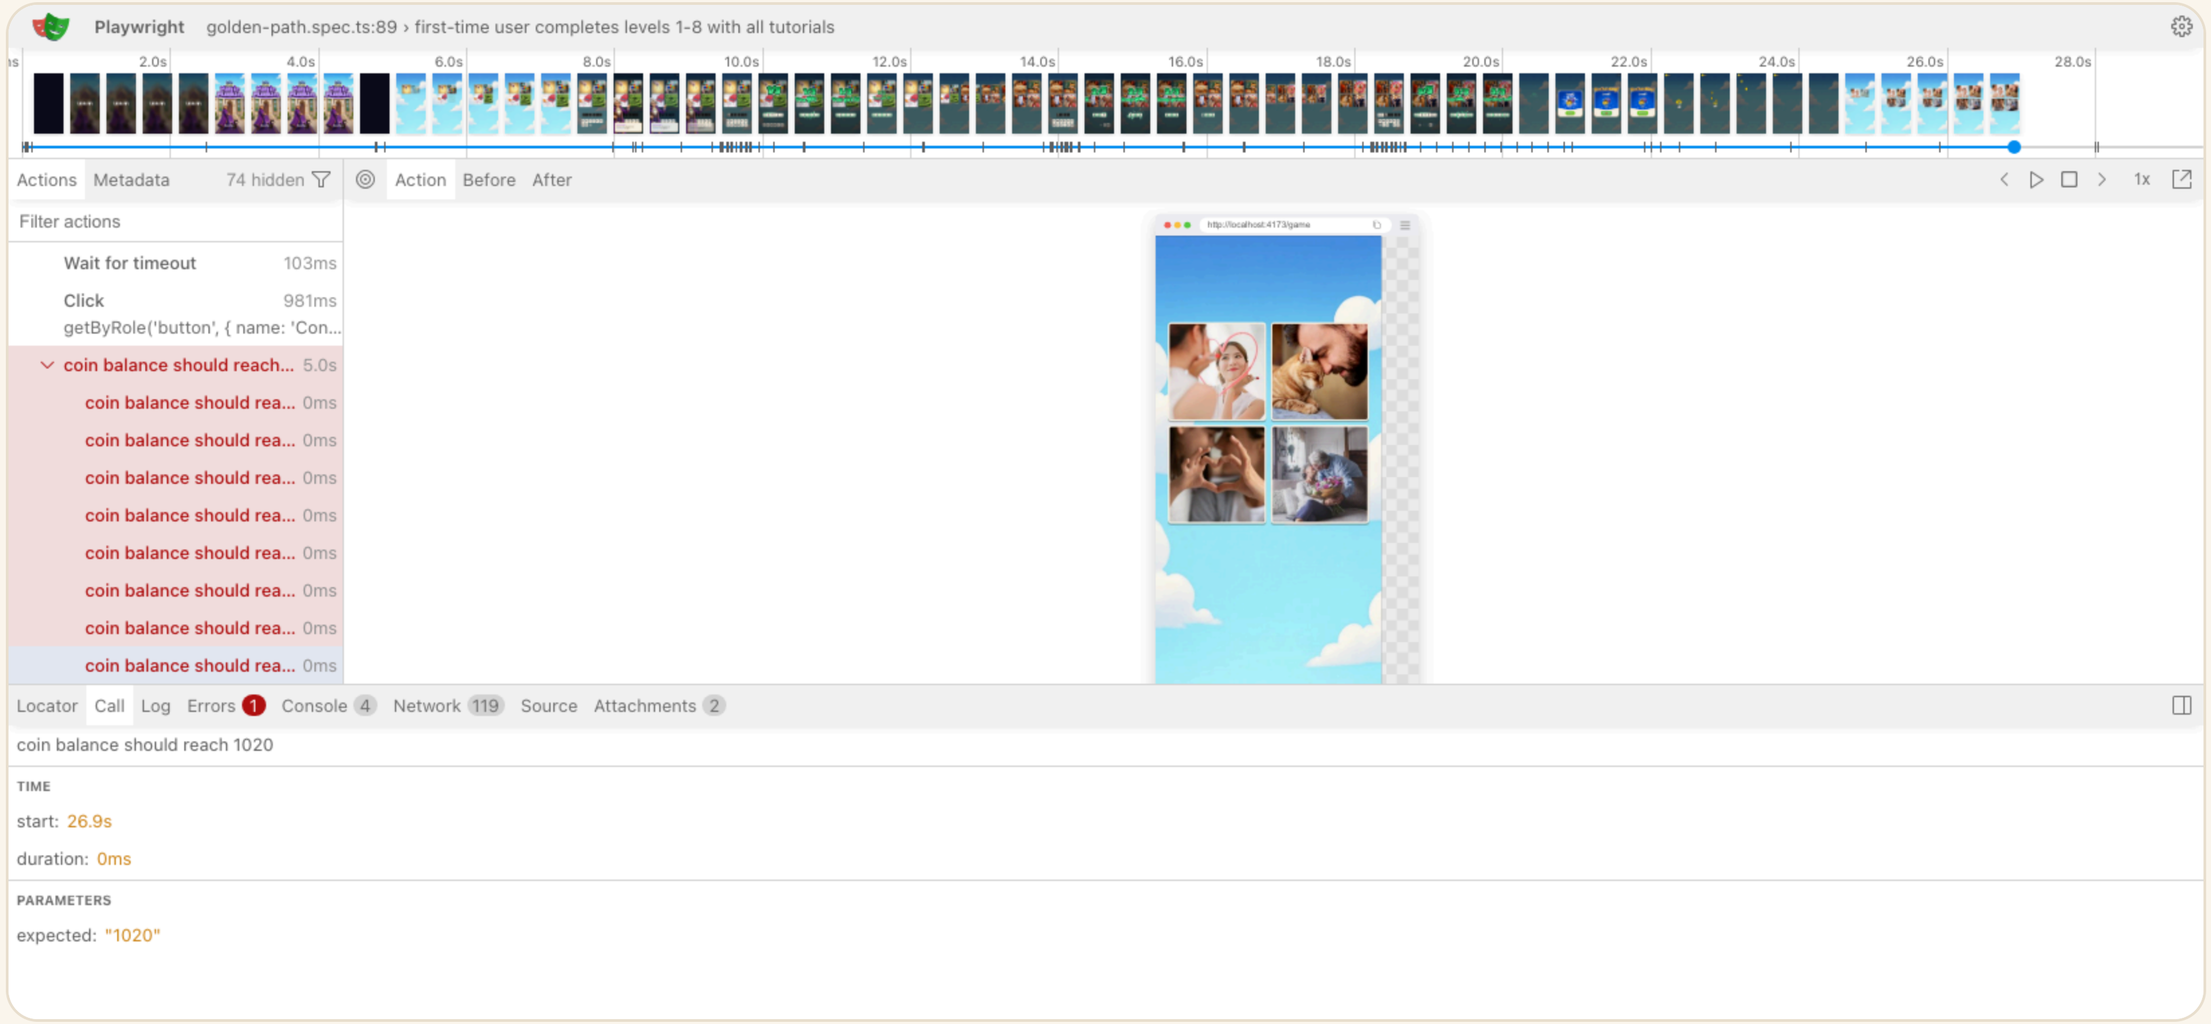
So sieht ein grüner PR aus



Und so ein roter



Wo genau ist es rot?



MAGIC MUSEUM · SETUP-CHECK

Golden Path: was klappt, was nicht

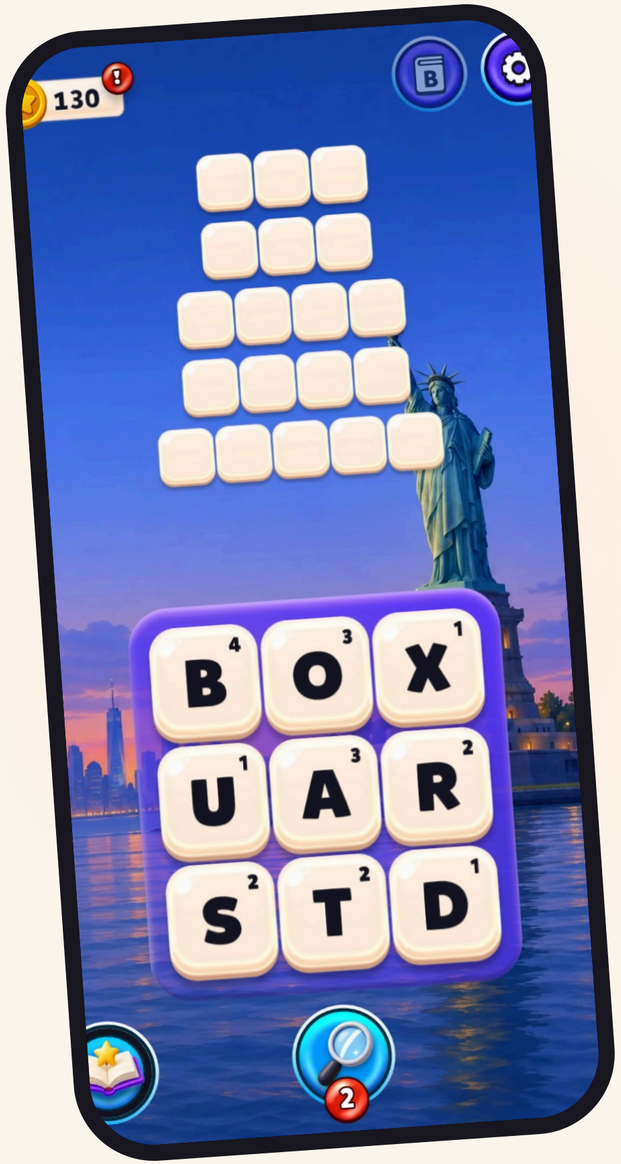
✅ Prüft das **Zusammenspiel**: Münzen, Spielstand und Tracking von vorne bis hinten

ℹ️ Erster Fehler **bricht den Lauf ab**, Video und Screenshots enden dort. Bewusst so gebaut

ℹ️ **Screenshots ohne Pixel-Vergleich:** ginge, aber bewusst nicht, im neuen Spiel ändert sich noch zu viel

⚠️ Neue App, wenig Verzweigung: **deutlich einfacher**

❌ **4 Minuten Video:** Wer schaut das bei jedem PR, und wo ist die Stelle, die mich interessiert?



PROJEKT 3 VON 3

Word Puzzle Journey

Ein **Wortpuzzle als Weltreise**: Buchstaben-Kacheln zu Wörtern wischen, jede Kachel nur begrenzt oft. Jedes Kapitel ist ein Reiseziel.

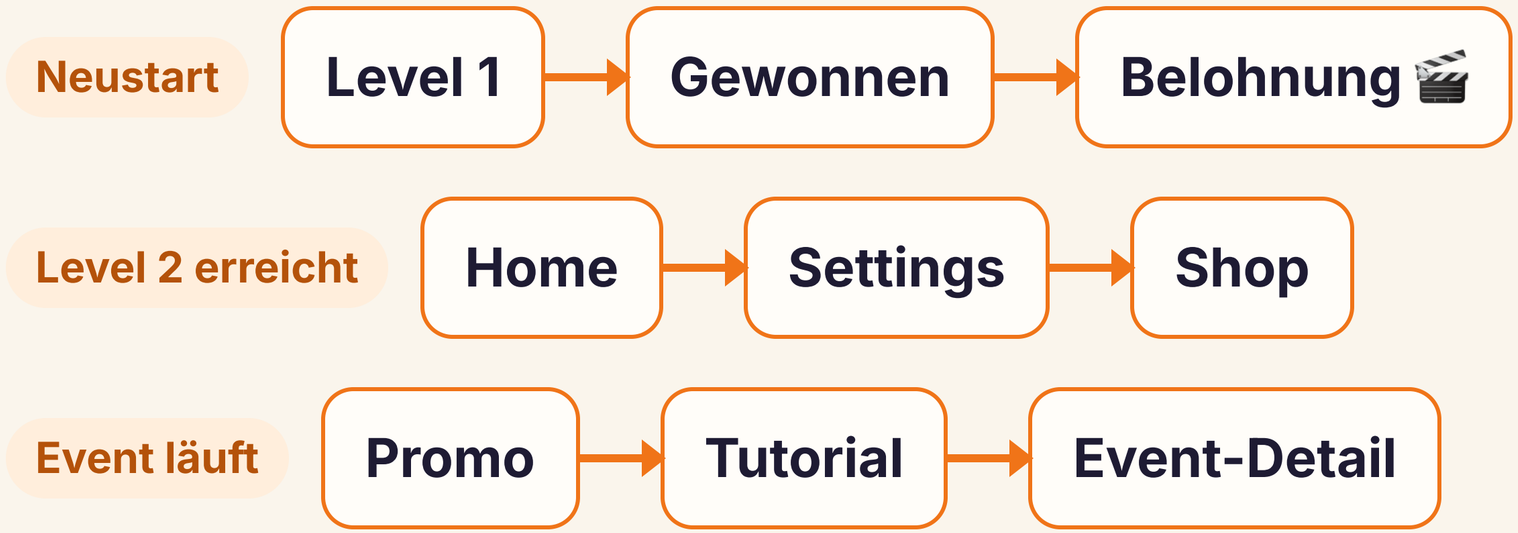
2 Wochen
vom Kick-off bis zum Release, dank AI

79
E2E-Tests nach drei Wochen

Designer
ändern selbst Code, mit AI

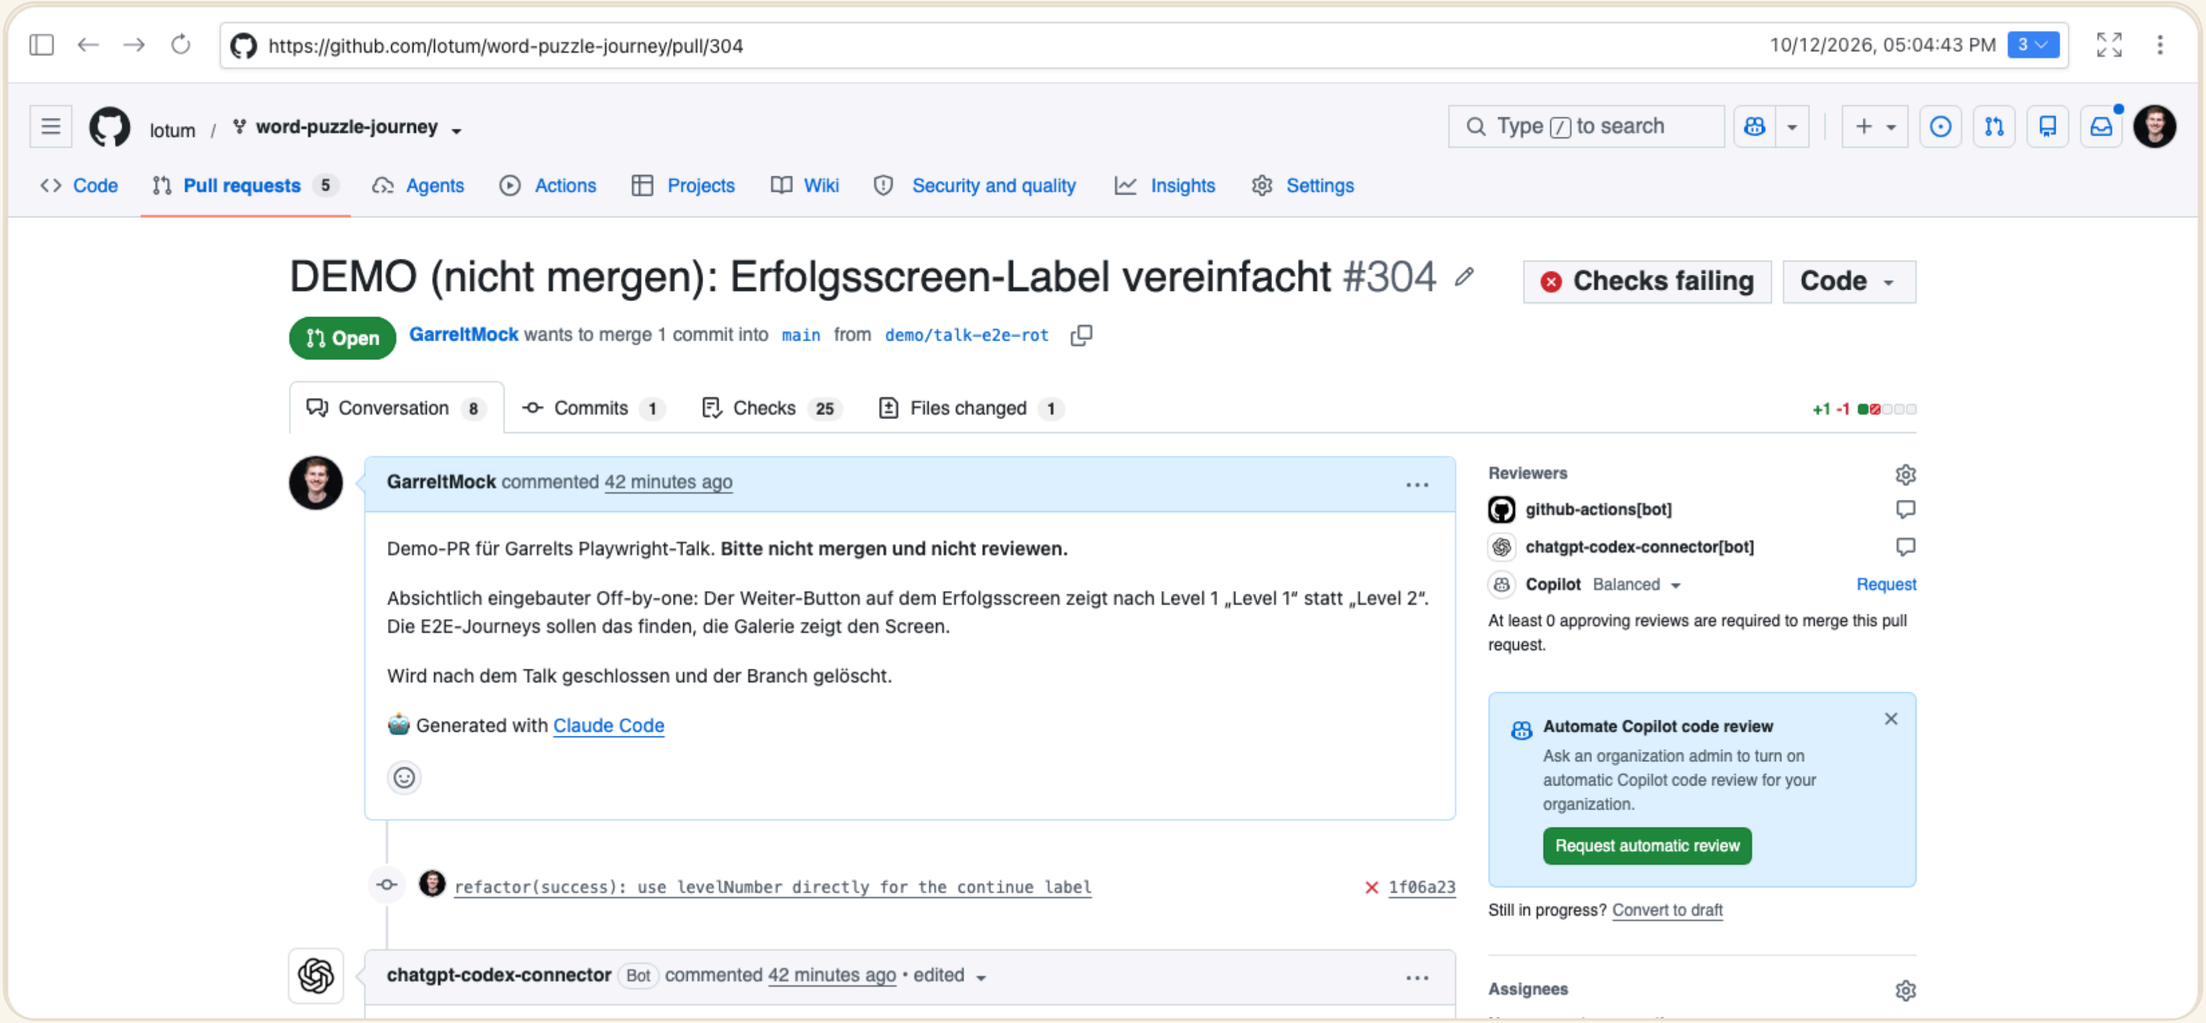
WORD PUZZLE JOURNEY · SETUP

Viele kleine Journeys



79 Tests, jeder startet frisch mit eigenem Spielstand

Die Galerie im PR



WORD PUZZLE JOURNEY · SETUP-CHECK

Journeys: was klappt, was nicht

- ✅ Designer trauen sich, **mit AI Code zu ändern**
- ✅ Jede Journey startet frisch: **ein Fehler betrifft nur sie**
- ✅ **Gezielte Bilder** im PR statt 4 Minuten Video

REALITY CHECK

Der Comic-Fehler?
Passiert kaum noch.

REALITY CHECK

Wie oft wird’s rot wegen AI?

0 von 9

Agent-Läufen machen den **Comic-Fehler** nach

fast nie

rot bei **Magic Museum**, sagt das Team

280

rote CI-Läufe bei **Word Blitz** in 14 Monaten

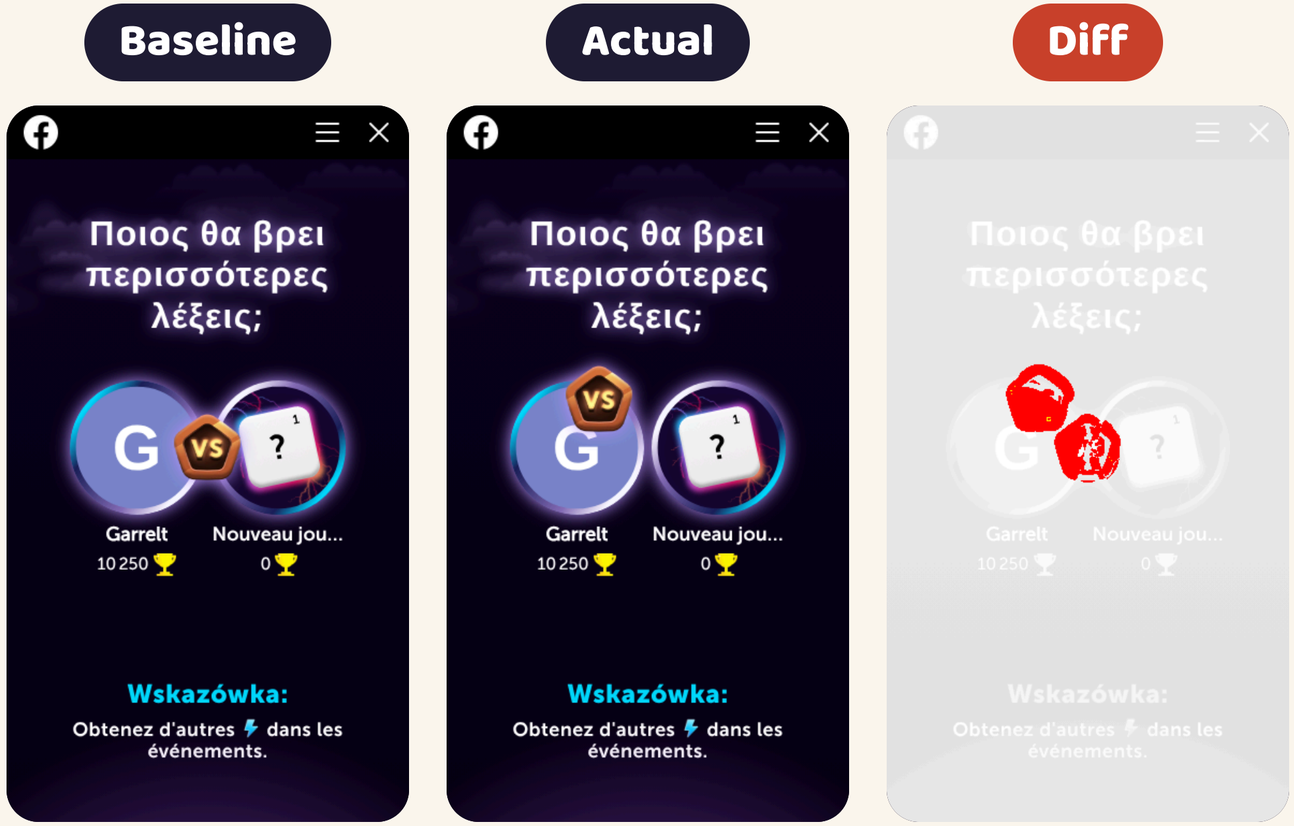
3

davon **echte Seiteneffekte** durch AI, alle im Code gefixt

„Goal: no visible change“

282 Dateien geändert

Der Check: **4 Screens rot**.
Der Agent fixt den Code,
nicht die Baseline.



REALITY CHECK

Selten rot.

Aber dann zu Recht.

Und Grün heißt: Ich kann mit gutem Gefühl mergen.


Sicherheitsnetz

FAZIT

Was könnt ihr erwarten?

DREI SETUPS · FÜR WEN IST WAS DRIN?

Was bringt das wem?

🤖 AI

Sieht, was sie **nebenbei kaputt macht**, und fixt den Code.

👨‍💻 Dev

Baut die Checks einmal und **muss nicht jeden Diff lesen**. Business-Regeln sind hart abgesichert.

🎨 Design · PM

Ist **enabled**, am Code zu arbeiten. Sieht im PR, **wie es aussieht**.

SCHICHTEN STATT KONKURRENZ

Kombinieren, je nach Projekt

SCHICHT	WANN SINNVOLL
⚙️ **Verhalten prüfen**	**immer**, zuerst dort, wo es fürs **Business** zählt
🖼️ **Pixel prüfen**	großes Bestandsprojekt, das Aussehen soll **stabil** bleiben
👀 **Ergebnisse zeigen**	so, wie es für **das Team** funktioniert

WAS IHR MITNEHMEN KÖNNT

Unsere Learnings

🏁 Was nicht **in CI** läuft, läuft nicht

🌱 **Klein anfangen**, mit der App wachsen

🛠️ Devs **bauen** die Checks, alle **nutzen** sie

⏱️ E2E ist der **langsamste** CI-Job

Schon gesehen: 🐋 Docker · 🎞️ Kein Zufall · 👀 Mensch entscheidet · 🔴 Code fixen

ZUM SCHLUSS

Vertrauen ist gut, Screenshots sind besser

... wenn jemand hinschaut. 🤖 👨‍💻 🎨

WHAT'S NEXT

Zum Weiterlesen

📘 **playwright.dev**: Wir nutzen nur einen Bruchteil. Stöbern lohnt sich

🪄 **Stagehand**: Playwright mit Prompts statt Selektoren

⚡ **Blacksmith**: schnellere Runner für GitHub Actions

Slides zum Nachlesen



Fragen?

Garrelt Mock · garrelt@programmier.bar